

DỰ BÁO GIÁ KIM LOẠI QUÝ SỬ DỤNG CÁC MÔ HÌNH THỐNG KÊ, HỌC MÁY VÀ HỌC SÂU

1. Phan Minh Trí

Khoa Hệ thống Thông tin

Trường Đại học Công nghệ Thông tin
21522709@gm.uit.edu.vn

2. Võng Thanh Linh

Khoa Hệ thống Thông tin

Trường Đại học Công nghệ Thông tin
21521082@gm.uit.edu.vn

3. Lê Nguyễn Hoàng Huy

Khoa Hệ thống Thông tin

Trường Đại học Công nghệ Thông tin
21520915@gm.uit.edu.vn

4. Trần Hạnh Thảo

Khoa Hệ thống Thông tin

Trường Đại học Công nghệ Thông tin
21522609@gm.uit.edu.vn

5. Nguyễn Thị Tường Vi

Khoa Hệ thống Thông tin

Trường Đại học Công nghệ Thông tin
21522787@gm.uit.edu.vn

Tóm tắt nội dung—Trên thị trường hiện nay, vàng (Gold), bạch kim (Platinum) và Palladium là các kim loại quý hiếm, có giá trị cao và nhu cầu về các kim loại này không bao giờ giảm. Xu hướng tỷ giá của kim loại quý cho thấy đây là một trong những phương án đầu tư tốt nhất hiện nay. Vì vậy, mối quan tâm đến việc sử dụng các mô hình thống kê, học máy và học sâu để hiểu rõ và dự báo xu hướng của tỷ giá này có ý nghĩa rất lớn đối với nền kinh tế đất nước. Bài báo sẽ nghiên cứu các ý tưởng dự báo tỷ giá vàng (Gold), bạch kim (Platinum) và Palladium bằng các mô hình: Linear Regression (LR), Exponential Smoothing Trend (ETS), ARIMA, Random Forest (RF), Support Vector Regression (SVR), Recurrent Neural Network (RNN), Gated Recurrent Unit (GRU), Long Short Term Memory (LSTM), Timesnet, Autoformer. Nghiên cứu áp dụng 10 mô hình dự báo khác nhau để tìm ra mô hình nào hoạt động tốt nhất trên tập dữ liệu có sẵn. Bộ dữ liệu về giá kim loại quý được chia theo tập train:test với 3 tỷ lệ là 6:4, 7:3, 8:2. Sau đó thực hiện so sánh hiệu suất của các mô hình dựa trên ba độ đo: MSE, RMSE, MAPE. Cuối cùng, thực hiện dự báo giá của kim loại quý trong 30, 60 và 90 ngày tiếp theo đối với tất cả mô hình. Kết quả cho thấy mô hình TimesNet, RNN và GRU có hiệu suất ổn định nhất và có thể giúp cải thiện dự báo. Từ đó, đưa ra các quyết định hiệu quả trong thị trường thực tế và giúp ích cho việc phát triển và đầu tư vào các kim loại quý.

Từ khóa—Dự báo, Kim loại quý, LR, ETS, ARIMA, RF, SVR, RNN, GRU, LSTM, TimesNet, Autoformer

I. GIỚI THIỆU

Hiện tại, trong bối cảnh nền kinh tế thế giới nói chung và Việt Nam nói riêng đang diễn biến 1 cách phức tạp và khó dự đoán kể từ sau đại dịch COVID-19. Các lĩnh vực chủ đạo của nền kinh tế ít nhiều bị biến động, do đó giá của các kim loại quý như vàng (Gold), bạch kim (Platinum) và Palladium cũng bị biến động theo nền kinh tế hiện tại. Và việc dự báo giá cũng là 1 vấn đề quan trọng trong lĩnh vực tài chính và đầu tư. Việc dự báo chính xác giá của các kim loại quý này có thể giúp các nhà đầu tư, doanh nghiệp và các tổ chức khác đưa ra quyết định sáng suốt về việc mua bán, nắm giữ hoặc đầu tư vào chúng. Nắm bắt được vấn đề hiện hữu, nhóm chúng tôi đã thực hiện nghiên cứu này với các mô hình dự báo chuỗi thời gian để có

thể đưa ra được các dự báo với tỉ lệ chính xác cao nhằm giúp ích cho việc phát triển và đầu tư.

Để dự báo giá của các kim loại quý, có khá nhiều thuật toán và kỹ thuật hỗ trợ cho việc này. Và trong nghiên cứu này, chúng tôi sẽ sử dụng 10 mô hình để áp dụng cho việc dự báo bao gồm: Linear Regression (LR), Exponential Smoothing Trend (ETS), ARIMA, Random Forest (RF), Support Vector Regression (SVR), Recurrent Neural Network (RNN), Gated Recurrent Unit (GRU), Long Short Term Memory (LSTM), Timesnet, Autoformer. Những mô hình này được áp dụng và sẽ dự báo giá của kim loại quý trong 30, 60 và 90 ngày tới.

Dựa vào kết quả dự báo, chúng tôi có thể phân tích, đánh giá và kiểm tra độ chính xác của các giá dự báo bằng cách so sánh với giá thực tế. Điều này giúp tinh chỉnh các mô hình và phương pháp dự báo để đạt độ chính xác cao hơn. Ngoài ra, các kết quả dự báo này có thể sẽ giúp cho các nhà đầu tư, doanh nghiệp và các tổ chức tài chính để họ sử dụng trong việc lập kế hoạch và đưa ra các quyết định đầu tư.

II. CƠ SỞ LÝ THUYẾT

Dự báo giá vàng bằng ARIMA, RW, ARFIMA, ETS, TBATS và MLR. Nghiên cứu của Alessio Azzutti[3], so sánh kết quả thu được từ 6 mô hình dự báo, để dự báo giá vàng. Nghiên cứu gồm 36 phạm vi dự báo khác nhau cả về dài hạn và ngắn hạn, từ kết quả thu được ta nhận thấy không có mô hình nào trong 6 mô hình có thể đưa ra dự báo chính xác nhất về giá vàng trong cả ngắn hạn và dài hạn. Tuy nhiên dựa trên RMSE thì ARIMA cung cấp dự báo tốt hơn lần lượt là 5%, 2%, 1%, 54% và 55% so với mô hình RW, ETS, TBATS, ARFIMA và MLR.

Dự báo giá vàng bằng SES và ETS. Nghiên cứu của Mohamad As'ad, Sujito, Sigit Setyowibowo, Eni Farida, Eka Yuniar, Mahmud và Yunus[2], bài nghiên cứu tiến hành so sánh giữa SES và ETS trong dự đoán giá vàng. Kết quả cho thấy mô hình ETS cho ra dự báo tốt hơn so với SES.Theo tính toán mô hình ETS(M,N,N) là mô hình có giá trị AIC, BIC, MAPE

và RMSE nhỏ nhất, cụ thể AIC = 2902.143 , BIC = 2912.882, MAPE = 0.6513446 và RMSE = 15.01525.

Dự đoán giá vàng sử dụng mô hình ARIMA được nghiên cứu bởi Banhi Guha và Gautam Bandyopadhyay[5]. Trong nghiên cứu này, họ đã phân tích hiệu suất giá vàng trong 10 năm qua. Dựa trên giá được giao dịch trên MCX, trong sáu bộ tham số mô hình khác nhau cho thấy ARIMA(1,1,1) là mô hình dự đoán tốt nhất cho các giá trị tương lai của vàng và đáp ứng được tất cả các tiêu chí thống kê phù hợp.

Dự đoán giá vàng bằng các kỹ thuật học máy được nghiên cứu bởi Nandini Tripurana, Binodini Kar, Sujata Chakravarty, Bijay K. Paikaray và Suneeta Satpathy[8]. Họ đã sử dụng các thuật toán ANN, Linear regression, SVR, Random forest & Decision tree để dự đoán và kết quả cho thấy Random Forest có RMSE = 0.248 thấp nhất và R-squared = 0.98 cao nhất là thuật toán mang lại kết quả tối ưu nhất trong việc dự đoán giá vàng.

Haitham Fawzy, EL Houssainy A. Rady, Amal Mohamed Abdel Fattah[4] đã sử dụng mô hình SVM và KNN để dự báo giá vàng từ đó so sánh độ chính xác. Các mô hình SVM và K-NN được trang bị dựa trên 90% dữ liệu dưới dạng tập huấn luyện và sau đó độ chính xác của chúng được so sánh bằng cách sử dụng thước đo thống kê RMSE. Kết quả chỉ ra rằng SVM tốt hơn K-NN trong việc dự đoán giá vàng trong tương lai, dựa trên RMSE=33,77.

Madini O. Allassafi, Mutasem Jarrah, Reem Alotaibi[6] đã sử dụng mô hình RNN và LSTM để dự đoán sự lây lan của COVID-19 ở Malaysia, Morocco và Ả Rập Xê Út. Nghiên cứu cũng so sánh số ca mắc bệnh và số ca tử vong do COVID-19 tại các nước trên. Sau đó, họ dự đoán số ca mắc và tử vong trong 7 ngày tiếp theo dựa trên dữ liệu có sẵn đến ngày 3 tháng 12 năm 2020. Kết quả độ chính xác của các mô hình lần lượt là 97.34% RNN (Sigmoid), 93.32% RNN (Tanh) và 99.27% LSTM (ReLU).

Dự Báo Giá Vàng theo Đồng Rupiah sử dụng Phân Tích Đa Biến với Mạng Nơ-ron LSTM và GRU[10], Nghiên cứu của Sebastianus Bara Primananda và Sani Muhamad Isa. Nghiên cứu cho thấy mô hình tốt nhất để dự báo giá vàng thay đổi theo khoảng thời gian dự báo. Trong khoảng thời gian dưới ba năm, GRU đạt độ chính xác cao nhất, trong khi LSTM vượt trội với các khoảng thời gian trên ba năm. Việc điều chỉnh siêu tham số bằng Grid Search đã cải thiện đáng kể hiệu suất của LSTM, giảm RMSE 68% và MAPE 6.72. Nó cũng cải thiện độ chính xác của GRU, giảm RMSE 2% và MAPE 5.74.

Dự báo giá vàng bằng LSTM, Bi-LSTM và GRU, Nghiên cứu của Mustafa Yurtsever[12] về việc so sánh hiệu suất của ba mô hình đa biến (LSTM, Bi-LSTM và GRU) để dự đoán giá vàng bằng các biện pháp MAE, RMSE và MAPE. Kết quả cho thấy LSTM hoạt động tốt nhất với thông số batch size là 128, số epoch là 1000, dẫn đến MAPE = 3,18, RMSE = 61.728 và MAE = 48,85.

Các tiến bộ gần đây trong dự báo SWH (Significant Wave Height) được nghiên cứu bởi Zhuxin Ouyang, Yaoting Gao, Xuefeng Zhang, Xiangyu Wu và Dianjun Zhang[9] đã giới thiệu mô hình EMD-TimesNet, tích hợp chế độ phân tích thực nghiệm (Empirical Mode Decomposition) với mạng nơ-ron TimesNet. Mô hình này đạt giá trị RMSE là 0.0494, 0.0982, và 0.1573,

cùng hệ số tương quan (Correlation Coefficients) là 0.9936, 0.9747, và 0.9352 cho các dự báo 1 giờ, 3 giờ, và 6 giờ tương ứng. Phương pháp này vượt trội hơn hẳn các mô hình hiện có như TimesNet, Autoformer, Transformer, và CNN-BiLSTM-Attention.

Autoformer: Phân rã từ Transformer nhằm dự báo dữ liệu chuỗi thời gian với cơ chế Tự tương quan (Autocorrelation) được nghiên cứu bởi Haixu Wu, Jiehui Xu, Jianmin Wang, Mingsheng Long[11]. Trong nghiên cứu này, các tác giả đã thực hiện dự báo trên các lĩnh vực thực tế như: năng lượng, giao thông, kinh tế, thời tiết và bệnh tật. Kết quả đưa ra Autoformer có MSE và MAE tốt hơn so với các mô hình dự đoán chuỗi thời gian như Informer, LogTrans, Reformer, LSTNet và LSTM.

III. ĐỐI TƯỢNG NGHIÊN CỨU

A. BỘ DỮ LIỆU

Bộ dữ liệu sử dụng trong bài nghiên cứu lấy từ Markets Insider[7] - một trang web cung cấp tin tức thị trường chứng khoán, báo giá và biểu đồ theo thời gian thực. Bộ dữ liệu cung cấp thông tin chi tiết dữ liệu giá của 3 kim loại quý nổi bật nhất là: vàng (Gold), bạch kim (Platinum) và Palladium trong giai đoạn từ 01/01/2018 đến 01/06/2024. Dữ liệu bao gồm các cột:

- Ngày (Date): Ngày giao dịch cụ thể.
- Giá mở cửa (Open): Giá của kim loại quý khi bắt đầu phiên giao dịch trong ngày.
- Giá đóng cửa (Close): Giá của kim loại quý khi kết thúc phiên giao dịch trong ngày.
- Giá cao nhất (High): Giá cao nhất mà kim loại quý đạt được trong phiên giao dịch.
- Giá thấp nhất (Low): Giá thấp nhất mà kim loại quý đạt được trong phiên giao dịch.

Tuy nhiên, do mục tiêu của nghiên cứu là dự báo giá đóng cửa, nên chỉ tập trung xử lý dữ liệu liên quan đến cột "Close". Trong trường hợp có các ngày giao dịch bị thiếu dữ liệu, phương pháp nội suy tuyến tính sẽ được áp dụng để ước tính giá trị đóng cửa dựa trên các giá trị liền kề đã biết, đảm bảo tính liên tục và đầy đủ của dữ liệu cho quá trình phân tích và dự báo. Công thức nội suy tuyến tính:

$$y = y_1 + \left(\frac{x - x_1}{x_2 - x_1} \right) \cdot (y_2 - y_1)$$

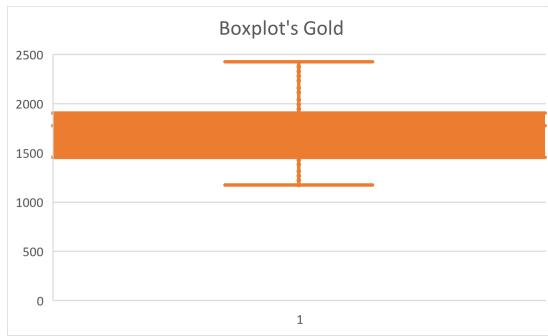
Chú thích:

- y: Giá trị cần tìm.
- y1: Giá trị Close của ngày gần nhất trước ngày có giá trị bị thiếu.
- y2: Giá trị Close của ngày gần nhất sau ngày có giá trị bị thiếu.
- x: Ngày tại giá trị cần tìm y.
- x1: Ngày tại giá trị Close y1.
- x2: Ngày tại giá trị Close y2.

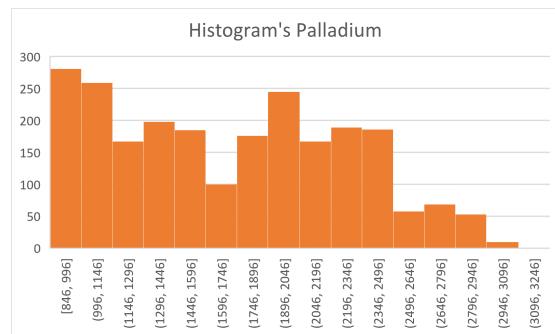
B. MÔ TẢ THỐNG KÊ

	Gold	Palladium	Platinum
Count	2344	2344	2344
Mean	1697.529	1719.441	942.257
Std	284.059	563.265	105.219
Min	1174.115	846	595
25%	1456.6	1215.875	869.5
50%	1778.345	1724.875	931.5
75%	1904.25	2182.75	1000
Max	2425.49	3178	1306

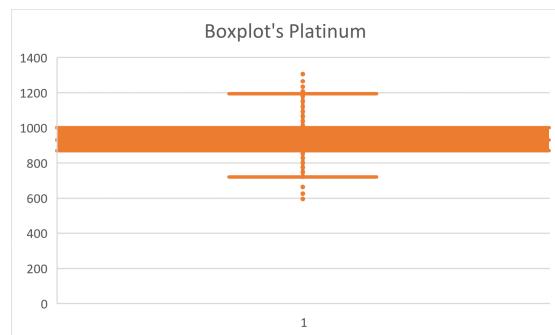
Bảng I: Mô tả thống kê của bộ dữ liệu



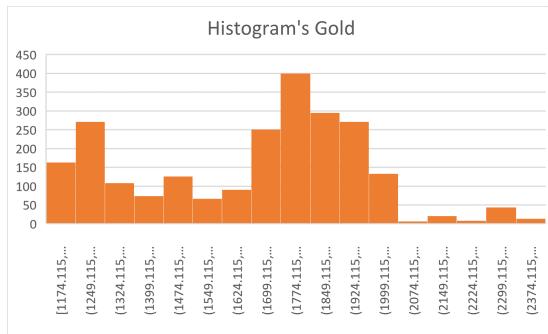
Hình 1: Sơ đồ boxplot của vàng (Gold)



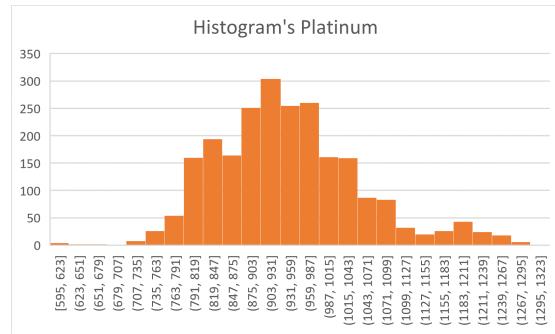
Hình 4: Sơ đồ histogram của Palladium



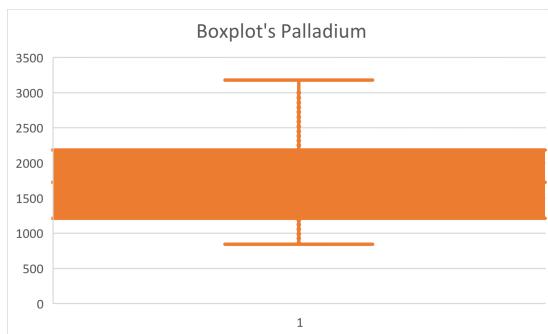
Hình 5: Sơ đồ boxplot của bạch kim (Platinum)



Hình 2: Sơ đồ histogram của vàng (Gold)



Hình 6: Sơ đồ histogram của bạch kim (Platinum)



Hình 3: Sơ đồ boxplot của Palladium

Dựa vào mô tả thống kê giá đóng cửa của ba kim loại quý: vàng (Gold), bạch kim (Platinum) và Palladium, với số lượng quan sát bằng nhau là 2344. Giá trị trung bình của Gold là 1697.529, thấp hơn so với Palladium (1719.441) và cao hơn so với Platinum (942.257). Tuy nhiên, Palladium có độ lệch chuẩn cao nhất (563.265), cho thấy sự biến động lớn nhất trong khi Platinum có độ lệch chuẩn thấp nhất (105.219), biểu thị sự ổn định hơn. Các biểu đồ boxplot và biểu đồ histogram cho thấy sự phân bố giá trị của các kim loại này, với Gold và Palladium có sự phân bố không đều và Platinum có phân bố gần chuẩn hơn. Bộ dữ liệu này cung cấp một cái nhìn tổng quan về sự biến động giá của ba kim loại quý, là cơ sở cho các phân tích tiếp theo.

IV. PHƯƠNG PHÁP NGHIÊN CỨU

A. Linear Regression (LR)

Linear Regression là một phương pháp dùng để xác định mối quan hệ giữa một biến phụ thuộc và một hoặc nhiều biến độc lập. Mối quan hệ này được mô tả bằng một phương trình tuyến tính, trong đó biến phụ thuộc được thể hiện là một hàm tuyến tính của các biến độc lập.

Khi chỉ có một biến độc lập, chúng ta gọi là hồi quy tuyến tính đơn giản (Simple Linear Regression). Trong trường hợp có nhiều biến độc lập, ta gọi là hồi quy tuyến tính đa biến (Multiple Linear Regression).

Simple Linear Regression được mô tả qua công thức:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Trong đó:

- y : biến phụ thuộc (dependent variable) cần dự đoán.
- x : biến độc lập (independent variable) được sử dụng để dự đoán giá trị của y .
- β_0 : hệ số gốc (intercept) của đường hồi quy, đại diện cho giá trị dự đoán của y khi $x=0$.
- β_1 : hệ số hồi quy (regression coefficient), đại diện cho mức độ thay đổi của y dựa trên mỗi đơn vị thay đổi của x .
- ε : lỗi ngẫu nhiên (random error), biểu thị sự không thể tránh khỏi của mô hình trong việc mô phỏng dữ liệu thực tế.

B. Exponential Smoothing Trend (ETS)

ETS (Exponential Smoothing hay Error, Trend, Seasonal) là một phương thức dự báo chuỗi thời gian, mỗi mô hình được xác định bởi ba thành phần:

• **Error** (Sai số): Đây là những biến động ngẫu nhiên, không thể dự đoán trước trong chuỗi thời gian. Mô hình ETS có thể xử lý sai số theo hai cách: cộng dồn (cộng sai số vào dự báo) hoặc nhân lên (nhân sai số với dự báo).

• **Trend** (Xu hướng): Thể hiện hướng đi chung của chuỗi thời gian (tăng, giảm hay không có xu hướng). Mô hình ETS có thể xem xét các xu hướng khác nhau như không có xu hướng, xu hướng tăng đều (tuyến tính) hoặc xu hướng tăng nhanh dần (dùng hàm mũ).

• **Seasonal** (Tính mùa vụ): Đây là những biến động lặp lại theo chu kỳ. Mô hình ETS cũng có thể xử lý tính mùa vụ theo hai cách tương tự như sai số là cộng dồn hoặc nhân lên.

Trong nghiên cứu này, chúng tôi đã sử dụng phương pháp tìm kiếm lưới (grid search) để xác định tổ hợp tham số tối ưu (bao gồm: sai số, xu hướng, tính mùa vụ, chu kỳ và xu hướng giảm dần) cho mô hình ETS. Mục tiêu là tìm ra mô hình có sai số dự báo thấp nhất (đánh giá bằng MSE) trên tập dữ liệu huấn luyện, sau đó áp dụng mô hình này để dự báo 30, 60, 90 ngày cho cả ba tập dữ liệu.

C. ARIMA

Mô hình ARIMA (Autoregressive Integrated Moving Average) được giới thiệu lần đầu bởi George Box và Gwilym Jenkins vào đầu những năm 1970. Đến nay, mô hình ARIMA đã trở thành một công cụ cơ bản trong phân tích và dự báo chuỗi thời gian và thường được biểu thị với bộ tham số là (p, d, q) .

Auto-Regressive (AR): Sử dụng một tổ hợp tuyến tính của các giá trị quá khứ của biến. Một mô hình tự hồi quy (AR) bậc p có thể được viết là:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

Trong đó:

- Y_t là giá trị hiện tại.
- $\phi_1, \phi_2, \dots, \phi_p$ là các tham số của mô hình.
- ε_t là sai số ngẫu nhiên.

Integrated (I): Ám chỉ việc đạo hàm của dữ liệu chuỗi thời gian.

Moving Average (MA): Sử dụng các sai số dự báo quá khứ trong một mô hình tương tự hồi quy. "q" là số lượng giá trị sai số trước đó được xem xét cho dự báo.

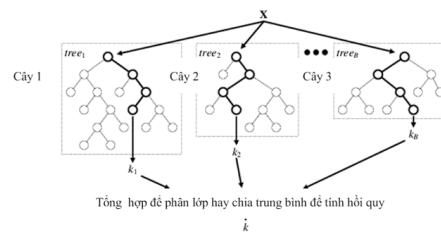
$$Y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

Trong đó:

- Y_t là giá trị hiện tại.
- c là hằng số.
- $\theta_1, \theta_2, \dots, \theta_p$ là các tham số của mô hình.
- ε_t là sai số ngẫu nhiên.

D. Random Forest (RF)

Random Forest là một phương pháp học máy mạnh mẽ, được sử dụng để thực hiện các nhiệm vụ phân loại, hồi quy và nhiều tác vụ khác bằng cách xây dựng nhiều cây quyết định và kết hợp chúng lại thành một "rừng". Mỗi cây quyết định trong rừng được huấn luyện trên một mẫu dữ liệu con được lấy ngẫu nhiên từ tập dữ liệu gốc và sử dụng một tập con ngẫu nhiên của các thuộc tính tại mỗi nút để đưa ra dự đoán.



Hình 7: Sơ đồ biểu diễn các cây quyết định trong Random Forest

Mỗi node trong cây quyết định đại diện cho một thuộc tính, và các nhánh biểu thị các giá trị có thể của thuộc tính đó. Bằng cách đi từ gốc đến các node của cây theo các giá trị thuộc tính, cây quyết định có thể dự đoán giá trị đầu ra cho một đối tượng. Điểm mạnh của nhóm thuật toán cây quyết định là khả năng áp dụng vào các bài toán phân loại và hồi quy. Vì vậy, Random Forest có thể được sử dụng để phân tích và dự báo chuỗi thời gian. Random Forest cũng có khả năng đánh giá tầm quan trọng của các thuộc tính, giúp chúng ta hiểu rõ hơn về ảnh hưởng của từng thuộc tính đến kết quả dự đoán. Từ hình trên, ta có thể thấy rằng Random Forest bao gồm nhiều cây quyết định. Khi nhận đầu vào là một đối tượng x , mỗi cây sẽ đưa ra dự đoán riêng về giá trị của biến mục tiêu. Những dự đoán này sau đó được tổng hợp lại bằng cách lấy trung bình để đưa ra quyết định cuối cùng của mô hình.

E. Support Vector Regression (SVR)

SVM (Support Vector Machines) là một phương pháp máy vector hỗ trợ được sử dụng cho các bài toán phân loại. Mục tiêu của SVM là tìm một siêu phẳng (hyperplane) tốt nhất phân chia dữ liệu thành các lớp khác nhau. Tuy nhiên, trong bài toán dự đoán giá kim loại quý, cần quan tâm đến việc dự đoán một giá trị thực (giá kim loại) dựa trên đặc trưng đầu là giá đóng cửa (Close). Do đó, chúng tôi sử dụng SVR để tìm cách dự đoán một giá trị thực. SVR sẽ tìm một hàm hồi quy tốt nhất mà sai số của các dự đoán nằm trong khoảng chấp nhận được. SVR có thể sử dụng các hàm hạt nhân (kernel) để chuyển đổi không gian đầu vào sang không gian đặc trưng cao giúp cho việc xử lý các dữ liệu tuyến tính và phi tuyến. Một kernel tuyến tính là tích vô hướng đơn giản giữa hai vector đầu vào, trong khi một kernel phi tuyến là một hàm phức tạp hơn có thể nắm bắt các mẫu phức tạp hơn trong dữ liệu.

Không giống như các mô hình hồi quy truyền thống, SVR tập trung vào việc giảm thiểu lỗi dự đoán thay vì khớp dữ liệu một cách chính xác. Để đạt được điều này bằng cách tìm một siêu phẳng tối ưu hóa khoảng cách hay biên, giữa các giá trị dự đoán và các điểm dữ liệu thực tế. SVR đạt được sự cân bằng giữa tính đơn giản và tính linh hoạt bằng cách cho phép một mức đúng sai nhất định, hay biên độ lỗi, xung quanh các giá trị dự đoán.

Hàm hồi quy trong SVR:

$$f(x) = \langle w, x \rangle + b$$

Hàm mất mát E-insensitive:

$$L(y, F(x_i, \hat{w})) = \max(0, y - F(x_i, \hat{w}) - \varepsilon)$$

Trong đó:

- $L(y, F(x_i, \hat{w}))$: hàm lỗi.
- y : giá trị thực.
- $F(x_i, \hat{w})$: sai số ngẫu nhiên.
- ε : tham số điều chỉnh cho phép sai lệch.

Dưới đây là một số hàm kernel có thể sử dụng trong SVR

Kernel	Hàm
Linear	$f(X_1, X_2) = X_1^T X_2$
Polynomial	$f(X_1, X_2) = (X_1^T X_2 + 1)^d$
Sigmoid	$f(X_1, X_2) = \tanh(\alpha x^T y + x)$
RBF	$f(X_1, X_2) = e^{-\frac{\ x_1 - x_2\ ^2}{2\sigma^2}}$

Bảng II: Bảng tổng hợp các hàm kernel của SVR

Linear: Đây là kernel đơn giản nhất và cơ bản nhất trong SVR. Linear phù hợp khi dữ liệu có thể được phân tách tuyến tính trong không gian đầu vào.

Polynomial: Kernel này biến đổi dữ liệu đầu vào không gian đa thức, được xác định bởi tham số bậc và hệ số độ lệch.

Sigmoid: Kernel này biến đổi dữ liệu đầu vào thành không gian phi tuyến bằng cách sử dụng hàm sigmoid. Hàm sigmoid áp dụng phép biến đổi phi tuyến lên tích vô hướng của hai vector đầu vào. Ngoài ra có thể được sử dụng cho các bài toán có dữ liệu nhị phân.

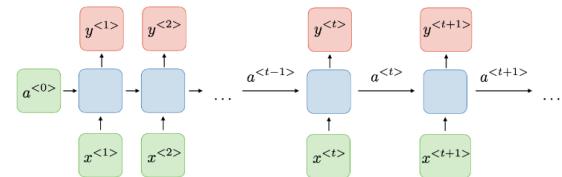
RBG: Đây là kernel phi tuyến phổ biến và cho phép mô hình học các cấu trúc phi tuyến phức tạp. Hàm RBG được xác định bởi tham số độ dốc.

F. Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN) là một mạng neural hồi quy sử dụng dữ liệu tuần tự hoặc chuỗi thời gian với 3 thành phần chính là Input layer, Hidden layer và Output layer[1].

Điểm đặc trưng của RNN là "bộ nhớ" của chúng cho phép sử dụng các thông tin từ đầu vào trước đó để ảnh hưởng đến đầu vào và đầu ra hiện tại, khác với mạng nơ-ron truyền thống.

Trong bài toán dự đoán giá vàng, RNN sử dụng 2 lớp SimpleRNN và Dense với từng vai trò khác nhau. Lớp SimpleRNN có tác dụng trích xuất các đặc trưng của dữ liệu chuỗi thời gian để nhận diện và học các bước xu hướng thời gian trước đó. Trong khi đó lớp Dense nhận các trích xuất đặc trưng từ lớp SimpleRNN và tổng hợp thông tin từ các đơn vị trong lớp RNN để áp dụng các phép biến đổi tuyến tính hoặc phi tuyến. Từ đó, dưới sự kết hợp của 2 lớp, mô hình RNN có thể đưa ra dự đoán giá vàng trong tương lai một cách chính xác.



Hình 8: Kiến trúc RNN

RNN được biểu diễn bằng công thức sau:

$$a^{<t>} = g_1(W_{aa}a^{<t-1>} + W_{ax}x^{<t>} + b_a) \quad (1)$$

$$y^{<t>} = g_2(W_{ya}a^{<t>} + b_y) \quad (2)$$

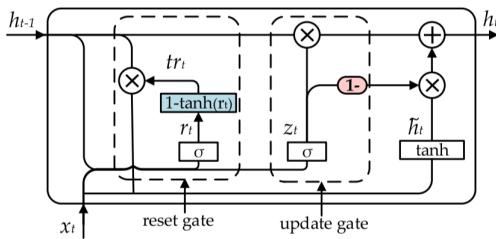
Trong đó:

- $x^{<t>}$: giá trị đầu vào tại thời điểm t
- $y^{<t>}$: giá trị đầu ra tại thời điểm t
- $a^{<t>}$: giá trị kích hoạt
- W_{aa}, W_{ax}, W_{ya} : các ma trận trọng số
- b_a, b_y : vector độ lệch
- g_1, g_2 : các hàm kích hoạt

G. Gated Recurrent Unit (GRU)

GRU (Gated Recurrent Unit) là một trong những kiến trúc mạng nơ-ron tái lập (RNN) phổ biến được sử dụng. GRU giúp mô hình học cách xử lý và dự đoán các chuỗi dữ liệu thời gian một cách hiệu quả, bằng cách giải quyết các vấn đề như sự biến mất đạo hàm và khó khăn trong việc lưu trữ thông tin dài hạn. GRU bao gồm hai cổng chính: cổng cập nhật (update gate) và cổng khôi phục (reset gate). Cả hai cổng này giúp kiểm soát luồng thông tin trong mỗi bước thời gian của chuỗi đầu vào và quyết định xem thông tin nào sẽ được truyền tiếp và thông tin nào sẽ bị loại bỏ.

Cổng Cập Nhật (Update Gate): Xác định mức độ thông tin mới sẽ được lưu trữ trong trạng thái ẩn mới (hidden state). Nó quyết định phần nào của trạng thái ẩn cũ nên được cập nhật bằng thông tin mới từ đầu vào hiện tại.



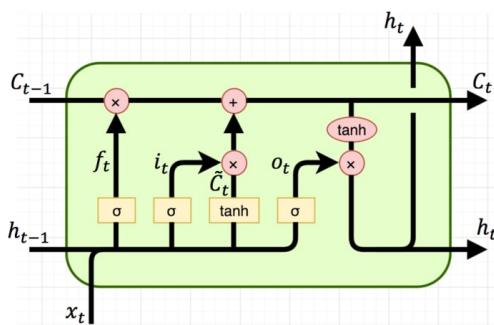
Hình 9: Kiến trúc GRU

Cổng Khôi Phục (Reset Gate): Quyết định phần nào của trạng thái ẩn cũ sẽ được "quên" hoặc đặt lại. Nó xác định cách sử dụng thông tin từ các bước trước đó để tính toán trạng thái ẩn mới.

Sự kết hợp của hai cổng này cho phép GRU hiệu quả trong việc xử lý các chuỗi dài và giữ lại thông tin quan trọng trong quá trình huấn luyện.

H. Long Short Term Memory (LSTM)

LSTM – là 1 dạng đặc biệt của mô hình RNN (Recurrent Neural Network), có khả năng học được các phụ thuộc. Phương pháp chính của mô hình LSTM là trạng thái tế bào (cell state), nó tương tự như 1 băng truyền chạy xuyên suốt tất cả các mảnh xích và tương tác tuyến tính với các mảnh xích đó vì vậy mà các thông tin dễ dàng truyền đi thông suốt mà không sợ bị thay đổi. LSTM sở hữu khả năng chọn lọc thông tin quan trọng bằng cách loại bỏ hoặc thêm vào trạng thái (state) của nó. Quá trình này được kiểm soát bởi các cấu trúc được gọi là cổng (gate). Mỗi cổng hoạt động như một bộ lọc thông tin, quyết định lượng thông tin được phép đi qua. Cụ thể, cổng bao gồm một lớp mạng sigmoid, tạo ra một giá trị trong khoảng từ 0 đến 1, đại diện cho tỷ lệ thông tin được truyền qua. Giá trị 0 nghĩa là không có thông tin nào được truyền qua, trong khi giá trị 1 cho phép tất cả thông tin đi qua. LSTM sử dụng ba cổng như vậy để quản lý và điều chỉnh trạng thái của tế bào: cổng quên (forget gate), cổng vào (input gate) và cổng ra (output gate).

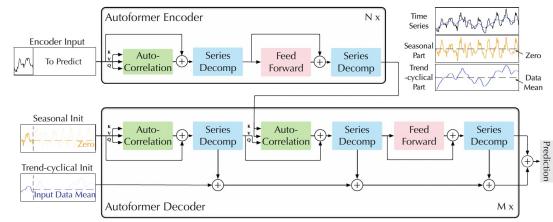


Hình 10: Kiến trúc LSTM.

I. Autoformer

Autoformer là 1 mô hình học sâu (Deep Learning) cải tiến kiến trúc phân rã từ mô hình Transformer truyền thống để phân tách dữ liệu chuỗi thời gian thành các thành phần (components) theo mùa (seasonality) và xu hướng (trend). Bao gồm kiến trúc

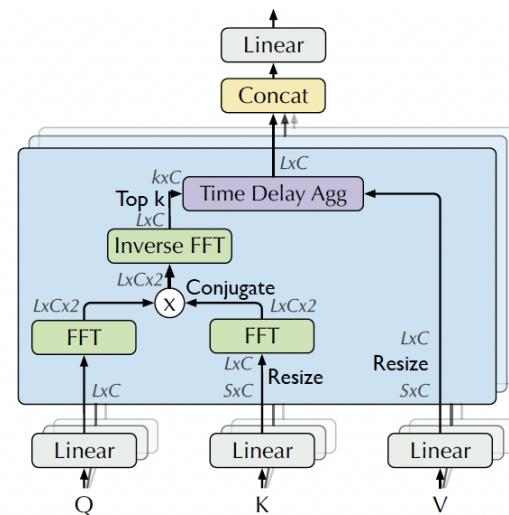
phân rã sâu, cơ chế tự động tương quan (Autocorrelation), bộ mã hóa (Encoder) và bộ giải mã (Decoder) tương ứng.



Hình 11: Tổng quan mô hình Autoformer.

Decomposition Architecture – kiến trúc phân rã được xây dựng để nhằm nâng cao khả năng mô hình phân tách các thành phần trên chính xác hơn. Series decomposition block - khối phân tách dữ liệu dạng chuỗi, được sử dụng để trích xuất dần dần xu hướng ổn định dài hạn từ các biến ẩn trung gian được dự đoán. Cụ thể hơn, đó là thực hiện điều chỉnh đường trung bình động để làm dịu đi các biến động định kỳ và làm nổi bật các xu hướng dài hạn. Khối Encoder - bộ mã hóa, có nhiệm vụ tập trung vào việc mô hình hóa các thành phần có tính mùa vụ, đầu ra của khối Encoder này chứa thông tin theo mùa trong quá khứ và sẽ được sử dụng làm thông tin chéo để giúp bộ giải mã tính chính xác dự đoán. Tiếp theo là đến khối Decoder - bộ giải mã, gồm 2 thành phần: cấu trúc tích lũy cho các thành phần theo chu kỳ xu hướng và cơ chế Tự tương quan (Autocorrelation) xếp chồng cho các thành phần theo mùa.

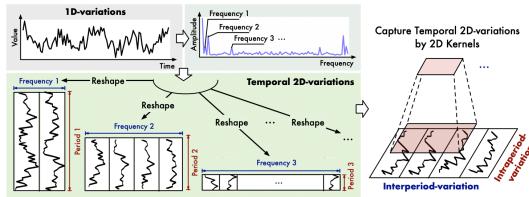
Như đã nói ở trên, Autoformer cũng giới thiệu 1 phương pháp tự động tương quan (Autocorrelation) cải tiến để thay thế cho self-attention trong mô hình Transformer chuẩn. Cơ chế tự động tương quan này phát hiện các phụ thuộc dựa trên thời gian bằng cách tính toán tự tương quan chuỗi và tổng hợp các chuỗi con tương tự bằng cách tổng hợp độ trễ thời gian, cho phép mô hình tận dụng sự phụ thuộc theo thời gian, từ đó cải thiện hiệu suất của mô hình tổng thể.



Hình 12: Cơ chế Auto-Correlation.

J. TimesNet

Là phương pháp mô hình hóa biến thiên 2D theo thời gian để phân tích chuỗi thời gian tổng quát. Hành động tách các khoảng thời gian khác nhau khỏi chuỗi thời gian có thể làm giảm đáng kể độ phức tạp để xử lý các mô hình.



Hình 13: Minh họa cấu trúc 2D trong chuỗi thời gian.

Chuỗi thời gian 1D được chuyển đổi thành nhiều tensor 2D. Mỗi tensor đại diện cho một chu kỳ cụ thể được xác định thông qua quá trình FFT. Việc biến đổi này được điều chỉnh bởi các phương trình sau:

$$X_f = FFT(X)$$

$$A_f = \frac{1}{d} \sum_{i=1}^d |X_f[i]|$$

$$P_k = \frac{T}{k}$$

$$X_{2D}^{(k)} = \text{reshape}(X, P_k)$$

Trong đó:

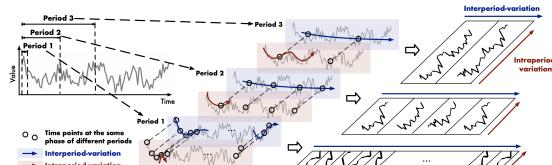
- X : chuỗi thời gian ban đầu.
- X_f : đại diện cho FFT của nó.
- A_f : phổ biên độ.
- P_k : độ dài chu kỳ cho tần số k.
- $X_{2D}^{(k)}$: tensor 2D được định hình lại cho chu kỳ.

TimesNet sử dụng một kiến trúc mô-đun với nhiều Times-Block, mỗi khối được thiết kế để xử lý các tensor 2D và nắm bắt các biến thiên thời gian. Một TimesBlock được định hình như sau:

$$H_{l+1} = F(H_l) + H_l$$

Trong đó:

- H_l : đầu vào cho TimesBlock thứ l.
- F : biểu thị chuỗi các biến đổi được áp dụng trong khối.



Hình 14: Chuyển đổi chuỗi thời gian 1D ban đầu thành một tập hợp các tensor 2D dựa trên nhiều chu kỳ.

K. Độ đo

Để đánh giá năng lực dự đoán của các mô hình sử dụng trong nghiên cứu, chúng tôi sử dụng ba phép đo hiệu suất bao gồm: Mean Absolute Percentage Error (MAPE), Root Mean Square Error (RMSE) và Mean Square Error (MSE).

Độ đo MAPE đo lường sai số tuyệt đối trung bình giữa giá trị dự đoán và giá trị thực tế với công thức sau:

$$MAPE = \frac{\sum_{i=1}^n \left(\frac{|f_i - y_i|}{y_i} \right)}{n}$$

Độ đo MSE tính toán trung bình bình phương của các sai số giữa giá trị thực tế và giá trị dự báo với công thức sau:

$$MSE = \frac{\sum (f_i - y_i)^2}{N}$$

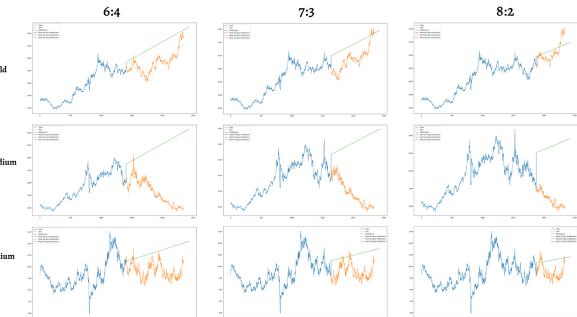
Độ đo RMSE đo lường khoảng cách trung bình giữa các giá trị dự đoán và thực tế với công thức sau:

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (f_i - y_i)^2}{n}}$$

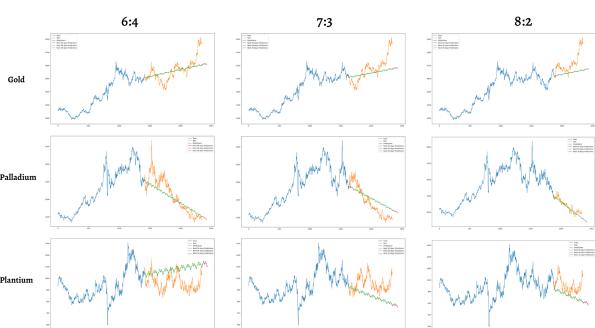
Trong đó:

- f_i là giá trị dự đoán cho mẫu thứ i.
- y_i là giá trị thực tế cho mẫu thứ i.
- N là số lượng mẫu.

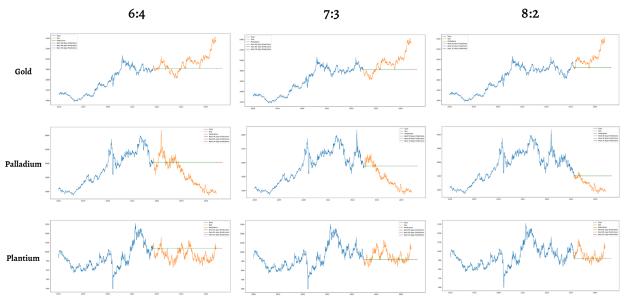
V. THỰC NGHIỆM



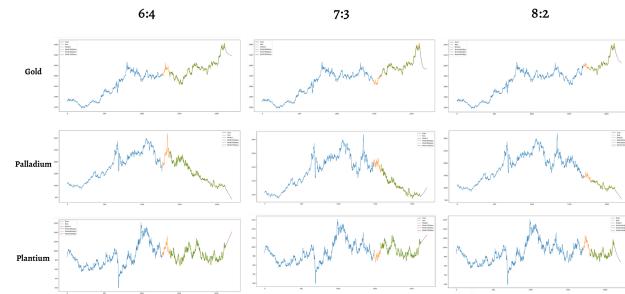
Hình 15: Kết quả thực nghiệm Linear Regression



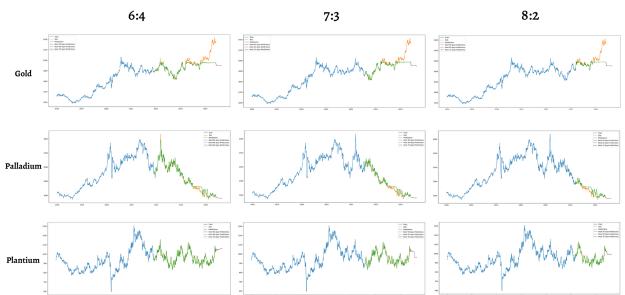
Hình 16: Kết quả thực nghiệm ETS



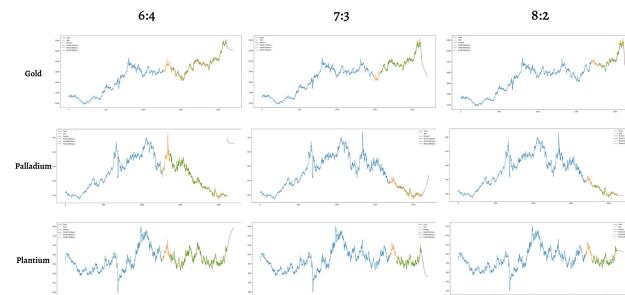
Hình 17: Kết quả thực nghiệm ARIMA



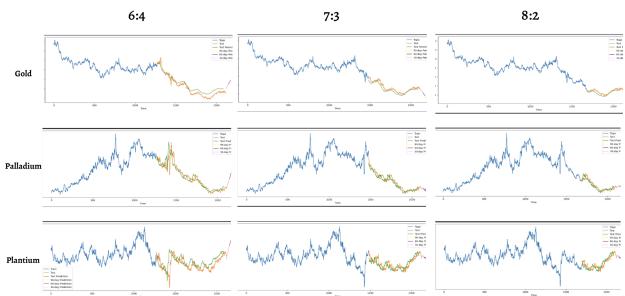
Hình 21: Kết quả thực nghiệm GRU



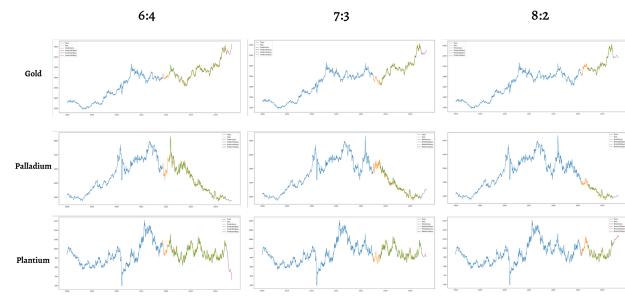
Hình 18: Kết quả thực nghiệm Random Forest



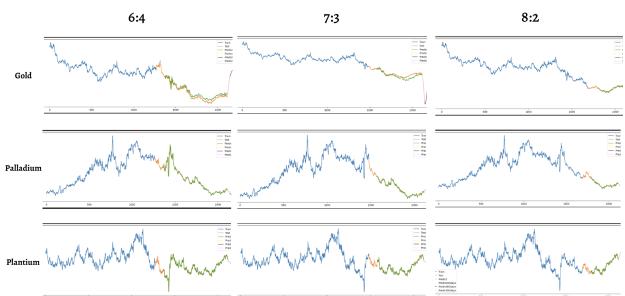
Hình 22: Kết quả thực nghiệm LSTM



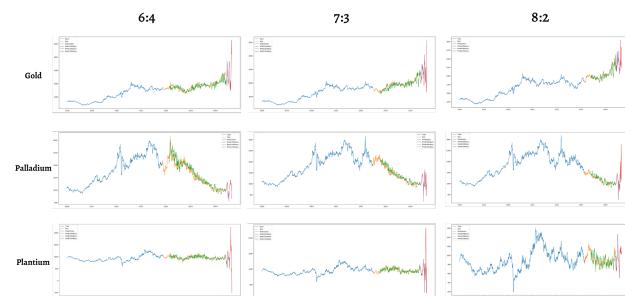
Hình 19: Kết quả thực nghiệm SVR



Hình 23: Kết quả thực nghiệm TimesNet



Hình 20: Kết quả thực nghiệm RNN



Hình 24: Kết quả thực nghiệm Autoformer

Mô hình	Độ do	Gold			Platinum			Palladium		
		6:4	7:3	8:2	6:4	7:3	8:2	6:4	7:3	8:2
LR	MSE	87892.376	60421.236	13670.770	33390.720	24896.165	13672.344	3807255.595	2885808.893	2314930.054
	RMSE	296.466	245.807	116.922	182.731	157.785	116.929	1951.219	1698.767	1521.489
	MAPE	0.145	0.122	0.049	0.175	0.155	0.114	1.373	1.308	0.133
ETS	MSE	16220.786	24542.912	36337.612	18391.562	16073.944	10671.415	70750.306	64441.255	7191.420
	RMSE	127.361	156.662	190.624	135.615	126.783	103.303	265.989	253.853	84.802
	MAPE	0.046	0.058	0.069	0.127	0.114	0.089	0.115	0.182	0.059
ARIMA	MSE	36441.460	46190.765	55921.673	9354.217	5213.863	4389.925	414476.127	352036.294	135397.298
	RMSE	190.896	214.920	236.477	96.717	72.207	66.256	643.798	593.326	367.963
	MAPE	0.069	0.082	0.088	0.090	0.053	0.047	0.430	0.441	0.299
RF	MSE	13503.084	15563.667	22068.984	222.475	197.399	162.232	4506.977	4252.035	5670.472
	RMSE	116.202	124.754	148.556	14.915	14.049	12.737	67.134	65.207	75.302
	MAPE	0.026	0.029	0.038	0.011	0.010	0.010	0.032	0.037	0.046
SVR	MSE	2923.408	1962.372	2093.366	893.129	794.283	714.362	21090.350	18557.479	24755.786
	RMSE	54.069	44.299	45.753	29.885	28.183	26.728	145.225	139.848	157.340
	MAPE	0.024	0.018	0.019	0.026	0.024	0.024	0.087	0.094	0.120
RNN	MSE	499.596	515.097	1517.604	393.092	372.776	311.441	4196.248	1908.821	1879.004
	RMSE	22.352	22.696	39.956	19.827	19.307	17.648	64.779	43.690	43.348
	MAPE	0.009	0.009	0.013	0.016	0.015	0.014	0.027	0.024	0.031
GRU	MSE	536.009	790.620	552.993	404.460	341.843	283.783	3888.186	1941.318	1134.122
	RMSE	23.151	28.117	23.515	20.111	18.488	16.845	62.355	44.060	33.676
	MAPE	0.008	0.010	0.008	0.015	0.014	0.013	0.025	0.023	0.024
LSTM	MSE	1136.599	1457.405	560.276	539.192	300.794	316.181	4022.841	2125.158	1378.915
	RMSE	33.713	38.176	23.67	23.221	17.343	17.782	63.425	46.099	37.133
	MAPE	0.013	0.015	0.008	0.019	0.015	0.015	0.027	0.026	0.025
TimesNet	MSE	496.222	350.124	372.906	333.390	252.735	193.083	3080.777	2100.171	888.844
	RMSE	22.276	18.711	19.310	18.258	15.897	13.895	55.504	45.827	29.813
	MAPE	0.008	0.006	0.007	0.015	0.013	0.011	0.022	0.025	0.019
Autoformer	MSE	8768.156	7598.881	6137.704	3299.357	2104.744	1820.022	19418.751	10928.070	5629.101
	RMSE	93.638	87.171	78.343	57.440	45.877	42.661	139.351	104.537	75.027
	MAPE	0.036	0.030	0.024	0.046	0.037	0.035	0.061	0.056	0.050

Bảng III: Bảng đánh giá kết quả thực nghiệm

Bảng trên ghi nhận các giá trị độ đo MSE, RMSE, MAPE của các mô hình Linear Regression (LR), Exponential Smoothing Trend (ETS), ARIMA, Random Forest (RF), Support Vector Regression (SVR), Recurrent Neural Network (RNN), Gated Recurrent Unit (GRU), Long Short Term Memory (LSTM), Timesnet, Autoformer trên tập test của ba bộ dữ liệu Gold, Platinum, Palladium với 3 tập train:test là: 6:4, 7:3, 8:2.

Các giá trị có kết quả tốt nhất (có giá trị thấp nhất) của 3 độ đo MSE, RMSE và MAPE của mỗi tập train:test của mỗi bộ dữ liệu (Gold, Platinum và Palladium) được tô màu đỏ.

Với bộ dữ liệu Gold, TimesNet có MSE, RMSE và MAPE đạt được giá trị thấp nhất trong 3 tập train:test, và GRU cũng cho ra kết quả tốt với MAPE cũng đạt 0.008 trong tập 6:4.

Với bộ dữ liệu Platinum, Random Forest (RF) có MSE, RMSE và MAPE đạt được giá trị thấp nhất trong 3 tập train:test, và theo sau là TimesNet, RNN và GRU cũng cho ra kết quả tương đối tốt.

Với bộ dữ liệu Palladium, TimesNet có MSE, RMSE và MAPE đạt được giá trị thấp nhất trong 2 tập train:test (6:4 và 8:2), và RNN cho ra kết quả tốt trong tập 7:3 với MSE và RMSE thấp nhất, tương tự GRU với MAPE trong tập này.

Tổng kết lại, từ các phân tích về các độ đo MSE, RMSE và MAPE trên cả ba bộ dữ liệu với ba tập train:test. Chúng tôi nhận thấy rằng TimesNet, RNN, GRU và Random Forest đều cho ra kết quả tốt. Tuy nhiên, Random Forest chỉ thật sự tốt trên bộ dữ liệu Platinum. Do đó, chúng tôi sẽ lựa chọn các mô hình phù hợp là TimesNet, RNN hoặc GRU để có thể giúp cải thiện dự báo và đưa ra quyết định hiệu quả trong thị trường thực tế, đặc biệt là đối với các thị trường kim loại quý như vàng (Gold), bạch kim (Platinum) và Palladium.

VI. KẾT LUẬN

Trong bài báo này, chúng tôi đã thực hiện việc áp dụng các mô hình thống kê, học máy và học sâu để dự báo giá kim loại quý. Chúng tôi đã sử dụng các mô hình: Linear Regression (LR), Exponential Smoothing Trend (ETS), ARIMA, Random Forest (RF), Support Vector Regression (SVR), Recurrent Neural Network (RNN), Gated Recurrent Unit (GRU), Long Short Term Memory (LSTM), Timesnet, Autoformer trên ba bộ dữ liệu khác nhau để dự báo giá kim loại quý. Qua đó, chúng tôi đánh giá và so sánh hiệu suất của từng mô hình cho thấy TimesNet, RNN và GRU có kết quả khá tốt. Điều này chỉ ra tiềm năng của các mô hình dựa trên mạng nơ-ron sâu trong lĩnh vực dự báo giá kim loại quý.

Dù đạt được một số kết quả tích cực, nghiên cứu của chúng tôi cũng gặp phải một số thách thức. Một trong những thách thức đó là sự phức tạp và biến động của thị trường kinh tế, điều này làm cho việc dự báo giá kim loại trở nên khó khăn hơn.

Trong tương lai, chúng tôi dự định sẽ tiếp tục nghiên cứu và áp dụng các kỹ thuật tinh chỉnh mô hình để nâng cao hiệu quả dự báo. Ngoài ra, các mô hình nơ-ron sâu như TimesNet, RNN và GRU không chỉ giúp cải thiện độ chính xác của dự báo mà còn mở ra những cơ hội mới trong việc áp dụng trí tuệ nhân tạo để phân tích và dự báo các biến động phức tạp trong thị trường kim loại quý. Sự kết hợp giữa khả năng học hỏi sâu và khả năng xử lý dữ liệu chuỗi của các mạng nơ-ron này làm cho chúng trở thành công cụ quan trọng và hiệu quả trong nghiên cứu và thực tiễn đầu tư vàng (Gold), bạch kim (Platinum) và Palladium. Bên cạnh đó, chúng tôi sẽ xem xét việc sử dụng các mô hình mới nhất và phát triển phương pháp kết hợp giữa các mô hình khác nhau để tăng độ chính xác và độ tin cậy của dự báo. Chúng tôi cũng sẽ mở rộng phạm vi nghiên cứu bằng cách sử dụng thêm nhiều dữ liệu từ các thị trường kim loại quý khác nhau nhằm đạt được sự dự báo chính xác hơn.

LỜI CẢM ƠN

Chúng tôi xin chân thành cảm ơn PGS. TS. Nguyễn Đình Thuân và Kỹ sư Nguyễn Minh Nhựt vì sự hướng dẫn và đóng góp quý báu trong quá trình thực hiện bài báo này. Sự chỉ dẫn chuyên môn và kiến thức sâu rộng của PGS. TS. Nguyễn Đình Thuân cùng với sự hỗ trợ tận tình từ Kỹ sư Nguyễn Minh Nhựt đã cung cấp cho chúng tôi những nền tảng lý thuyết và phương pháp nghiên cứu cần thiết, giúp chúng tôi hiểu rõ hơn về kỹ thuật phân tích chuỗi thời gian và áp dụng vào dự báo giá kim loại quý.

Chúng tôi cũng xin bày tỏ lòng biết ơn đến các thành viên. Sự hợp tác, hỗ trợ lẫn nhau và chia sẻ kiến thức trong nhóm đã tạo nên một môi trường làm việc tích cực và là động lực để vượt qua những thách thức trong quá trình nghiên cứu. Những ý kiến đóng góp và các cuộc thảo luận nhóm đã giúp chúng tôi mở rộng tầm nhìn và hoàn thiện nội dung của bài báo.

Cuối cùng, chúng tôi xin gửi lời cảm ơn tất cả những ai đã đóng góp và hỗ trợ trong suốt quá trình. Sự đóng góp và hỗ trợ này đã đóng vai trò quan trọng trong việc hoàn thành bài báo và mang lại giá trị cho lĩnh vực nghiên cứu dự báo. Chúng tôi hy vọng rằng công trình này sẽ được phổ biến rộng rãi và tiếp tục khám phá những tiềm năng và ứng dụng mới trong lĩnh vực này.

TÀI LIỆU

- [1] Shervine Amidi Afshine Amidi. *Recurrent Neural Networks cheatsheet*. 2018. URL: <https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-recurrent-neural-networks> (**urlseen** 26/05/2024).
- [2] Mohamad As'ad. ‘Forecasting Performance Base on Exponential Smoothing with SES and ETS Model for Gold Price Forecasting’. **in** Vol 11 No 1 (2024) JATISI: (**march** 2024), **pages** 267–274. DOI: 10.35957/jatisi.v11i1.3804.
- [3] Alessio Azzutti. ‘Forecasting Gold Price: A Comparative Study’. **in**(february 2016): DOI: 10.13140/RG.2.1.4206.5686.
- [4] Haitham Fawzy **and others**. ‘COMPARISON BETWEEN SUPPORT VECTOR MACHINES AND K-NEAREST NEIGHBOR FOR TIME SERIES FORECASTING’. **in**(january 2020): **pages** 2342–2359. DOI: 10.28919/jmcs/4884.
- [5] Banhi Guha **and** Gautam Bandyopadhyay. ‘Gold Price Forecasting Using ARIMA Model’. **in**Journal of advance Management Journal: (**march** 2016), **pages** 117–121. DOI: 10.12720/joams.4.2.117-121.
- [6] Reem Alotaibi Madini O. Alassafi Mutasem Jarrah. ‘Time series predicting of COVID-19 based on deep learning’. **inaugust** 2021: DOI: 10.1016/j.neucom.2021.10.035.
- [7] Markets Insider: Stock Market News, Realtime Quotes and Charts. en. URL: <https://markets.businessinsider.com/> (**urlseen** 13/06/2024).
- [8] Sujata Chakravarty Nandini Tripurana Binodini Kar. ‘Gold Price Prediction Using Machine Learning Techniques’. **in**Advances in Computational Intelligence, its Concepts and Applications (ACI 2022): **volume** 3283. 2022, **pages** 274–281.
- [9] Zhuxin Ouyang **and others**. ‘Significant Wave Height Forecasting Based on EMD-TimesNet Networks’. **in**Journal of Marine Science and Engineering: 12.4 (2024). ISSN: 2077-1312. DOI: 10.3390/jmse12040536. URL: <https://www.mdpi.com/2077-1312/12/4/536>.
- [10] Sebastianus Primananda **and** Sani Isa. ‘Forecasting Gold Price in Rupiah using Multivariate Analysis with LSTM and GRU Neural Networks’. **in**Advances in Science, Technology and Engineering Systems Journal: 6 (**march** 2021), **pages** 245–253. DOI: 10.25046/aj060227.
- [11] Haixu Wu **and others**. *Autofomer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting*. **january** 2022. arXiv: 2106.13008v5 [cs.LG].
- [12] Mustafa Yurtsever. ‘Gold Price Forecasting Using LSTM, Bi-LSTM and GRU’. **in**European Journal of Science and Technology: (**december** 2021), **pages** 341–347. DOI: 10.31590/ejosat.959405.